

1 要約

ステガノグラフィ技術の主な目的はステガナリシス技術に対しステゴデータの認知性を最小化しつつ埋め込み率を最大化することである。しかし、しかしながら他の情報ハイディング技術とは対照的に、埋め込み者は認知性が採用となるカバーデータを選択する上での自由がある。この考えは提唱されてきた埋め込み技術の中で全く言及されないままだった。本論文では私達は3つのシナリオにそってその問題についての調査を行った。シナリオは埋め込み者がステガノグラフィ技術に対し

1. 全くの知識がない
2. ある程度の知識がある
3. 完全な知識がある

である。

例えば、2のケースにおいて、私達は研究を等してどんなシンプルな統計の尺度で埋め込み者を支援することができるのかを例示する。

2 はじめに

ほかのデジタルコンテンツとは対照的に、過去数年間のうち、画像の可能性を広げ、画像の特性に対するよりよい理解得る助けとなるを画像ベースのステガノグラフィに関する研究がたくさんあった。

またそのような技術の発展は文字通り、たくさんのステガナリシス技術の提案へとつながった。その読者はステガノグラフィとステガナリシス技術に対し包括的レビューを論文 [1] にて言及している。

現代的なステガノグラフィはシモンズの囚人（アリスとボブという2人の受刑者）問題 [2] において定式化されており、監視員であるウェンディの監視の中、受刑者は平面図の風景を企てるためにメッセージ M を伝えあった。

ステガノグラフィの目的はアリスが秘密のメッセージ M をカバーイメージに埋め込むことで（つまりはステガノグラフィだ）形作られていたのだ。（意訳）

そして、普通なら誰かがウェンディ監視官にもっとばれないようなよりよい埋め込み技術について証明するだろう。

論文 [3] で提唱されているようなベンチマークに基づいたものによって埋め込み技術が他と比べよいと推定される。

しかし、ステガノグラフィは透かしなどの技術とは違い、カバーデータはメッセージを運ぶ役割しか持たない。埋め込みの家庭でアリスが自由に画像を選んだいたように。

これ (Fig.1) はカバーデータの選択における一般的なブロック図だ。ステゴデータを手に入れたあと、アリスはステゴデータを送るか代わりの画像を選択するかどうかを決めるためにステゴデータとカバーデータを比べる。

こうすることで、彼女はステガナライザーによって間違った分類をされる（つまりは埋め込みがばれない）ようなカバーデータを選択する。

そのため強力なステガナライザーの存在下でさえ、彼女は認知性を下げるチャンスを増やすことができたのだ。

私達は2章で問題提起と解決法を述べ、3章でカバーデータとステゴデータの比較に使用される尺度について述べる。

私達は4章の実験を通して埋め込み者のカバーデータ選択においてどのような指標について議論すべきかを解説する。

そして5章にて結果についての考察と今後について述べる。

3 問題提起

上述したようにアリスはワーデンがご分類してしまうようなカバーデータを選択することで、（埋め込みに）気づかれる可能性を最小化することができた。

そのためには彼女はステガナライザーのふるまいを理解する必要があり、そして（分類）の決定方法に参考にする必要があった。

ステガナライザーの分類機能は画像内の特徴空間におけるハイパープレーンの決定関する位置に基づいてカバーデータとステゴデータを区別する。

特徴空間における識別性は、埋め込み処理によるステゴデータの統計計算誤差やカバーデータにおけるそのようなズレによる欠損に依存する。

事実アリスは埋め込み者であり、カバーデータとステゴデータの両方に対して（ズレを起こすことが？）可能であった。

埋め込み者が埋め込み用に画像をランダムに選択するのではなく選択可能でありかつ使用可能な画像を多く所有していると仮定し、私達はカバーデータとステゴデータの関係の評価尺度をベースとした単純ながらも効果的

な（画像選択における）ランク付けの手法を提案します。それによってアリスのステゴデータの選択を支援し、より偽陰性を生じさせることができます。

さらに、私達はステゴデータの検出性に影響を与える埋め込み法とは別に、カバー画像特性（圧縮率、サイズ）についても議論する。

一つに、アリスがステガナライザーに対するさまざまなレベルの知識を要すると仮定した3つのしなりを考えることができる。

1. 全く知らない：彼女はステガナライザーに対する知識を全く有していません。しかし、彼女は埋め込みによって変化するであろう一般的な特徴について着目し認知を回避する機会を増やすことができます。例えば、埋め込み処理に起因する jpeg の DCT 係数を最小化する。
2. 多少の知識はある：ありますがステガナライザーについて限られた範囲での知識を有していた場合。アリスはワードンのステガナライザーに対していくつかのアクセス方法を有していたと仮定できる。しかし、彼女のアクセスは2つの方法に限られている。第一に、彼女はステガナライザーへの入力と出力へのアクセス権のみを有している。このように、彼女は内部での動き（特徴的な点）を具体的に知ることはできません。第二に、彼女のアクセスは彼女が選択した入力画像に対するステガナライザーに対する決定を入手することが許されているにもかかわらず、時間的に制限されている場合である。ここでナニも知らない場合と比較すると、彼女はカバーデータの選択に使用される特定のしきい値を計算するためのテキストとステゴデータのセットと対応する捨て仮名ライザーの決定を使用することでより正確になり得る。
3. よく知っている：この場合、アリスはステガナライザーとワードンによって使用される統計的特徴に関する確かな知識を有している。そこで彼女は同様のステガナライザーを仮定する（※ 直訳だと訓練）ためにカバーデータとステゴデータのデータのセットを使用することができる。そして、アリスは仮定したステガナライザーに対してステゴデータのテストを行うことができ、またご分類されるカバーデータを識別することができる。この場合私達のアプローチはあまり意味をなさない。

この時点で、ステガナライザーによって私達のアプ

ローチに誤りが生じている（偽陰性によって）可能性あります。私達のランキング付けの手法はその誤り率に依存していることに注意してください。

もしステガナライザーの誤りがなければ、すべてのステゴデータは検出されるでしょう。そして私達のアプローチは役に立たないでしょう。

次のセクションではいくつかのカバーデータのプロパティについてと同様にカバーデータの選択において使用される指標をもとにカバーとステゴの関係についても調査する。

4 指標

4.1 カバーベース

埋め込み動作とは独立して使用されるカバーの特性はステガナライザーの性能に影響を与える。以下にレニューする2つの特性を述べる

1. 可変係数埋め込み処理によって利用される係数のセット。メッセージの内容は固定されているため、たくさんの可変係数を有する画像は比較的埋め込み処理によって生じる変化の数が少ない。
2. JPEG の質の要因 [3] の論文見てもらったらわかるけどいままでベンチマークとってたんだよね、そりゃもう厳しい実験で扱ってきたさ。JPEG の室の要因となる値はステガナライザーの性能と反比例するんだ。言い換えるとより高いクオリティの JPEG ならより低いパフォーマンスになるってことだね（意訳）

4.2 カバーとステゴの関係 ベース

まあどっちかしか手に入らないってわけじゃないし、じゃあ両方使って測定しちゃおうってわけwだから僕らって興味あるんだよね、生成されたファイルを測定する指標ってやつにさ。以下で僕らが採用し、選択の指標となる評価指標について紹介するよ（意訳）

1. カバーデータからの変化量単純にカバーとステゴの違いってわけ。超直感的だしわかりやすいよね。
2. MSE(PSNR) (略)
3. 予測誤差論文 [4] で提案されてる予測モデルで、僕らの実験だけで使用したまあローカルな指標さ（たぶんグローバルなものではなく自分たちの予測のもとに作成したもの）（正直ココはナニが言

いたいのかわからん) MSE との相関が予想されてるよ。

4. ワトソンのメートル法 (論文 [5]) は JPEG の画質の適量化に使用される近似的尺度のこと。つまり検出可能性はカバーとステゴの間に生じるこの手法の値の差が低い程低いはずである。

5. SSIM (略)

5 実験

論文 [3] で得られたグレースケール画像の大規模なデータセットから、私達は 85 以上の (JPEG の) 品質係数を備え、かつ少なくとも 1000px を備える画像を手いにれました。これらの画像は 680 480px に縮小し、95 および 75 の品質係数で JPEG 化しました。したがって異なる圧縮率を持つ 2 つの画像セットを約 13000 の画像から得ました。ステゴデータは論文 [7] の埋め込み法を用いて画像の画素数を元にした固定長のメッセージとともに生成されます。2 つのステガナライザーには FBS と WBS を採用しました。(論文 [8] と論文 [9])

ステガナライザーは (所有するうちの) 30 % のカバーとステゴによって学習 (訓練) された。メッセージ長を 1 ピクセルあたり 0.04 として品質係数 95 の JPEG 画像と使用した。75 のものでは 1 ピクセルあたり 0.05 とした。(論文 [3] から分かる通り、データセットは埋め込み法に依存する (つまりは埋め込み法によって生成されるステゴが異なるということ) ことから 2 つのデータに対する埋め込み率を変更することとした。)

1. 全く知らない: 埋め込み者がステガナライザーがどのようにカバーとステゴを区別するのか知らない場合、彼女はステガナライザーの決定と彼女の直感がよい相関を持つことを願って、直感によって埋め込みの影響が少なくなる画像を選ばなければならない。前章ではステガナライザーの出力と相関するであろういくつかの要素について述べた。(PSNR...SSIM...) カバー選択におけるそれら (PSNR...) の信頼性をテストするために、私達はステガナライザーを設計する上で使用する指標とに学習中にステガナライザーからは見えない画像 (残りの 70 % ?) について議論することで研究を行った。

以下に実験手順を示す

- (a) 全体の 10 % の画像をランダムに選択し、TP の数を計算する (TP is 何???)

- (b) 指標に基づいて画像をソートする

- (c) 最大もしくは採用の 1 割の画像を選択し、TP 率を計算する。(PSNR なら最大、誤り率なら最小といった意味)

私達はステガナライザーは約 10 % 以上誤差を孕んでいると仮定して 10 % の最大 or 最小の 10 % の画像を選択した。

もし選択の範囲を少なくすればサンプル数が減ってしまうし、逆に増やせば、分類者の誤差率が少なかった場合にステガナライザーによる検出の可能性を上げることになってしまうだろう。

ステップ 1 で、私達は 10 % の画像がランダムに選択されたものと仮定してステゴデータとして正しく分類されてしまうであろうたくさんの画像に対し計算処理を行った。

ステップ 3 では、私達の単純なランク付け方式に則って正しく識別されたステゴデータに対し計算処理を行った。

結果、2 つの埋め込み解析 (FBS と WBS) の結果が得られた、表 1 に示す。

表 1 の題名: 知識のない中でのよいカバーデータの選択の改良補足: (*) がついているものは昇順にソートされたものです。このような (知識がない) 場合、大きい値ほどステゴデータの検出性が低くなった。その他のものは降順ソートしたものです。

表 1 より 2 つ (FBS と WBS) の実験結果において分類結果と指標との相関が異なることがわかる。例えば可変係数の最大値に対して FBS との識別率は正確ではなく、一方で WBS の性能には影響を与えていない。

2. 多少は知っている私達が実験を行った 2 つ目のシナリオは部分的な知識を備えている場合だ。この場合、私達は埋め込み者はいくつかのステゴに対するステガナライザーの決定を手に入れていると仮定する。そのため、アリスは先ほど示した指標についてのしきい値を知るための訓練のためにこれらの画像を使用することができる。例えば、テストデータのセットから計算された埋め込み過程の一部として生じたいくつかの変化の数よりも少ない変更をもつ画像を使用すればステガナライザーに対して認知されにくい。

前章と同じデータセットを使い、私達のアプローチが正確であることを調査するために以下のス

テップを実行した。

(a) トレーニング

- i. ステガナライザーの決定から得られた画像を使用して、上位または下位 1 割の画像を選択する。
 - ii. 選択した画像から得られた指標の平均値を計算する
3. テストするトレーニング段階で使用されなかった画像を使って、指標のしきい値で分類し（たぶん threshold で基準をもとにわけるとかってニューアンスになるのかと）（埋め込みの）結果のセットを使って TP の数を計算する。

表 2 の題名：FBS の行動予測における部分的な知識における画像選択の改善補足：表 1 と同じ
上記の実験を 10 回の繰り返し、私達は FBS と WBS それぞれの組み合わせに対しての非検知性の改善の平均値を計算した。表 2 は FBS 組み合わせから得られた結果を示している。何も知らない場合と部分的な知識がある場合に 10, 100, 500 の画像を埋め込みトレーニングに使用した場合のものだ。

例えば、私達何も知らない状態で MSE にもとづいて画像を選択したとすれば私達は確実に（FBS によって）発見されているだろう。

しかし 10 枚の画像を指標としきい値の調整に使用した場合、私達は TP 率を 99 % から 30 % まで改善することができた。表 3 に示すように同様の結果が WBS でも得られた。

表 3 の題名：WBS の～

6 結果

以上の研究で、カバーの選択における問題について言及し、シンプルだが効果的な解決策について調査を行った。

私達の設定では、アリスはウェンディーの仕訳機に対し限られたアクセスしか持っていなかった。しかしいくつかのステゴテストによる仕訳機の決定についての情報を持つことで、彼女はよりよいカバーの選択を行うことができた。

このために、彼女はステガナライザーの出力と同様のテストデータのクラス分けを行うための（しきい値と）（ゆがみの）指標を研究した。

私達は研究を通してどれほどの量のシンプルな指標が

ステガナライザーによる非認知性の改善につながるかを述べ、それぞれの指標を用いた場合のパフォーマンスについて調査した。

私達は MSE のような歪みの指標や誤りの予測は埋め込みによる歪みの質を測る上でよい指標とはならないということを見ることができた。

それはカバー - ステゴ間の歪みの減少はご認識の可能性を上げることにはならないということを示している。

しかし、表 1 のように逆は正しいです。

この問題はステガノグラフィーの理論的なフレームワークの開発になると考えられます。

例えば、FBS を用いた場合私達は MSE が高いほどにステゴデータが誤分類されていることがわかる。

（これは FBS はステゴデータを分割し再圧縮することでカバーデータを評価しているという意味なのかもしれない。カバーデータに注入された増加した歪みはより不正確な評価を生じさせ、同様に区別機の性能も小さくなる）

何も知らない場合、私達の結果はカバーに生じる変化を減らすことが信頼できる指標となることを示している。

一方、部分的な知識を持っている場合はその単純さにもかかわらず、MSE とか変形数の数はより低い検出性のカバーを選択する上での効果的な指標となった。

SSIM やワトソンのメートル法のような知覚的な指標においてこれらの指標の有意性もまた埋め込みによる歪みは統計的（というよりは知覚的）な方法で定量化する必要があることを示している。

加えて、テストデータの量による部分的な知識がもたらす可能性は（テストデータの数を）10 から 100 に増やすことでより効果的なものとなり、500 に増やすことはあまり大きな差を生じさせることはなかった。

私達は現在、代わりの指標を調査するだけでなく、より多くの埋め込み発見法をカバーしようと私達の仕事を拡大している。